上市保险公司年报问答知识库——方向 A 实验总结

一、实验目的

构建一个面向 10 家上市保险公司 2025 年年报的问答知识库：用户以自然语言提问，系统从年报原文中检索证据，由大模型严格依据检索到的材料作答，并给出可追溯到公司、报告、页码的引用；材料不足时必须明说不足，不得编造数字或页码。

二、数据与方法

- 数据：10 家 A/H 股上市保险公司 2025 年年报原文，共 7,507 个切块。其中 6 家为港股繁体年报，入库前做简繁归一（只作用于分词与向量层，切块原文不改，以保证引用逐字可核）。
- 切块：按章节切分并尽量保留表格的行列结构；每个切块携带公司、报告名、页码、章节、块类型等元数据。
- 检索：BM25（自实现 Okapi，k1=1.2、b=0.1）与向量检索（BAAI/bge-small-zh-v1.5，512 维）双路召回，用 RRF（k=60）融合，默认取 top-5。
- 生成：将 top-k 切块连同公司/报告/页码元数据送入 DeepSeek（deepseek-chat）。引用块由程序从切块元数据渲染、不经模型生成；另设相似度阈值、年份一致性、提示词三层闸门，并核查模型正文里出现的页码是否为材料所有。

三、实验结果

测试题数	10
人工判定答对	8（答案正确率 80%）
模型主动拒答（材料不足）	2
gold 页面召回	9 / 10
仅要求主 gold 页时的召回	5 / 10
编造数字 / 页码	0

判分口径：公司 + 页码同时命中才算召回 gold；“主 gold 页”指标注中的首要依据页。答对数由人工对着年报核对得出，脚本不代判。

四、典型错误

- q05「平安去年一年赚了多少钱？」——口语化提问使检索偏向“经营亮点”“内含价值分析”等页面，未召回净利润所在的财务摘要页（p14/p15）。模型如实回答“材料不足”，未编造，属检索失败而非生成失败。
- q09「国寿的保费规模有多大？」——提问用“国寿”“保费规模”，年报原文用“总保费”，简称与术语不一致，含精确值 7,298.87 亿元的 p13 未被召回。模型只拿到 p12 的“突破7,000亿元”，明确说明材料未给出确切数值；它也没有把同一指标在 q07 中已答对的数字挪来补答。
- 另有轻微偏差一处：q10 中模型把材料的“197,191 百万元”自行换算为“1,971.91 亿元”，与提示词“照抄单位、不要换算”不符。数值本身正确且出处可查，属指令遵循偏差，不是编造。

五、结论

当前系统的主要瓶颈在检索层，而不是生成层。10 道题中生成层未出现任何编造数字或页码；两次失败都是“该召回的证据没有进来”，而模型在证据不足时都选择了诚实拒答。口语化提问、公司简称与财报原文术语之间的映射，是当前最薄弱的环节。

六、改进方向

- 1. 查询改写：把口语问题改写成财报术语（如“赚了多少钱”→“归属于母公司股东的净利润”）。
- 2. 同义词与公司简称扩展：“国寿”→“中国人寿”，“保费规模”→“总保费”。
- 3. 提高 top-k：q09 在 top-10 下即可召回，代价是上下文变长、调用成本上升。
- 4. 加强章节与页码信息：用年报自带的目录页定位章节（港股 6 家的章节字段目前不可靠）。
- 5. 对 BM25 与向量检索的融合权重进一步调优，并针对表格型切块调整长度归一化。